


[M2S01] Ex. 01 - "War Room - O Consultor de Desastres"



Neste diagrama original acima, possivelmente teremos as seguintes falhas:

- O Power BI fazendo *DirectQuery* no banco de produção pode derrubar o sistema da empresa durante um pico de vendas.
- Processar 50 milhões de linhas em um notebook local é um gargalo manual, sem escala e sujeito a falhas de rede/hardware.
- Extrair 50M de registros todo dia é um desperdício massivo de recursos. O ideal é extrair apenas o que mudou (Incremental/CDC).
- Estes formatos de arquivos (CSV e Json) são pesados e lentos para análise. O sistema precisa varrer o arquivo inteiro para ler uma única coluna.

Para uma solução eficiente, vamos adotar o seguinte arquitetura:



Este diagrama ilustra o fluxo de dados ponta a ponta da nova arquitetura, desenhada para ser resiliente e escalável. Abaixo, temos a descrição da função de cada componente:

1. **Fonte (PostgreSQL):** O banco de dados transacional de produção. A nova arquitetura não o sobrecarrega com consultas diretas.
2. **Ingestão (Debezium & Kafka):**
 - **Debezium:** Monitora o log do banco de dados e captura qualquer alteração (CDC - Change Data Capture) em tempo real, sem onerar a performance do banco.
 - **Apache Kafka:** Atua como um buffer de alta performance, recebendo o fluxo de mudanças do Debezium e garantindo que nenhum dado seja perdido antes do processamento.
3. **Processamento (Apache Spark):** O motor de processamento distribuído que lê os dados do Kafka, realiza transformações complexas em memória e os grava no Data Lakehouse.
4. **Armazenamento (Data Lakehouse com Delta Lake):** Organiza os dados em camadas de qualidade crescente, usando o formato aberto **Delta Lake** para garantir transações ACID e performance.
 - **Bronze:** Dados brutos, exatamente como vieram da fonte, com histórico completo.
 - **Silver:** Dados limpos, validados, com tipos de dados corrigidos e duplicatas removidas.
 - **Gold:** Dados agregados e modelados em fatos e dimensões, prontos para análise de negócios.
5. **Consumo (Power BI):** A ferramenta de Business Intelligence conecta-se **exclusivamente à camada Gold**. Isso garante que os dashboards sejam rápidos e que o banco de produção esteja 100% protegido contra consultas analíticas pesadas.
6. **Governança e Orquestração:**
 - **Apache Airflow:** O "maestro" que agenda, inicia e monitora todo o pipeline de dados, garantindo que cada etapa ocorra na ordem correta e gerenciando falhas.
 - **dbt (data build tool):** Responsável por executar as transformações SQL dentro do Lakehouse (movendo dados da Silver para a Gold), aplicando testes de qualidade de dados automaticamente.